

研究室向けAI資料検索システム

本資料では、研究室に蓄積された論文や技術資料を効率よく探すための検索システムについて説明します。利用者は日本語の検索語を入力し、関連するPDF文書の一部分を類似度順に確認できます。

検索処理では、最初にPDFから本文テキストを抽出します。抽出した文章は約七百文字ごとのチャンクへ分割し、チャンクの境界では改行や文末を優先します。前後の文脈が失われないよう、隣接するチャンクには約百文字の重複を持たせます。

各チャンクは埋め込みベクトルへ変換されます。開発用のローカル埋め込みでは、日本語の単語と二文字・三文字の並びを固定次元へハッシュ化します。この方式は外部APIを必要とせず、同じ語句や近い文字列に対して決定的なベクトルを生成できます。

検索時には、質問文も同じ埋め込み方式でベクトル化します。Backendは保存済みチャンクとのコサイン類似度を計算し、スコアの高い順に上位の検索結果を返します。Webアプリは検索処理を持たず、REST APIを通じてBackendを利用します。

将来実装するSlack Botも、Webと同じ検索APIを使用します。これにより、検索ロジックや文書処理をクライアントごとに重複して実装する必要がありません。共有パッケージでは、Web、Slack Bot、Backendの間で利用するリクエスト型とレスポンス型を管理します。

今後はローカルJSONのRepositoryをSupabaseとpgvectorへ置き換えます。また、簡易埋め込みをGemini EmbeddingまたはE5へ差し替え、Google Driveからの文書取得、検索ログ、フィードバック保存を追加する予定です。

この段階では、大規模言語モデルによる回答生成、RAG、BM25、ハイブリッド検索、リランキングは実装しません。まずは日本語PDFの取り込みから検索結果表示までを一貫して動作させ、Backend中心の構成を検証します。